

Sealed Trade Protocol: 情報封印型交渉による P2P 相対取引基盤

Shota Nagafuchi

sealed-trade@proton.me

概要

相対取引における私的情報の漏洩を低減するプロトコルを提案する。従来の非公開市場では、交渉行為そのものが私的評価額を漏洩させ、相手方がその情報を利用して余剰を搾取する。オファーを通じて一度示された買い手の支払意思は、取り消すことができない。譲歩を通じて一度明らかになった売り手の緊急度は、永続的に交渉力を弱める。Sealed Trade は、ハードウェア隔離されたエンクレーブ内で動作する AI エージェント間に交渉を限定することでこの問題に対処する。各エージェントは暗号署名されたパラメータに束縛される。完了後にエンクレーブが終了し交渉状態がクリアされる。エンクレーブの境界を越えるのは最終的な合意または不成立の信号のみである。決済はステーブルコインを決済ルールとして用いるボンド付きスマートコントラクトによりオンチェーンで行われる。

1. はじめに

非公開の相対取引市場 — IP ライセンス、M&A、不動産 — では、合意に至るために交渉が不可欠である。しかし交渉行為そのものが破壊的である。あらゆるオファー、カウンターオファー、躊躇が、相手方が悪用しうる私的情報を暴露する。取引を成立させるために必要な情報と、条件を悪化させるために使用される情報は同一である。

我々はこれを**私的情報の二重使用**と呼ぶ。二者間で取引を交渉する際、各当事者の私的情報 — 留保価格、緊急度、代替選択肢 — は交渉過程で必然的に伝達される。一度伝達された情報は、公正な取引が生み出す以上の余剰を相手方が搾取するために使用される。

特許ライセンス交渉を考えよう。ライセンシーは支払える最大額を知っている。ライセンサーは受け入れる最小額を知っている。理想的な交渉では、いずれの当事者も相手方の境界を知ることなく合意可能領域 (ZOPA) 内の価格で合意する。しかし実際には、あらゆるオファーが情報を漏洩させる。10万ドルの初回提示は少なくともその金額の支払意思を示す。50万ドルの返答は最大でもその金額での受諾意思を示す。反復的なラウンドを通じて、各当事者の私的評価額は段階的に開示され、搾取される。

Myerson-Satterthwaite [1] は、私的評価額を持つ相対取引においてインセンティブ両立的な仕組みが事後効率性を達成できないことを証明した。我々はこの不可能性を回避するとは主張しない。パラメータ設定における戦略的緊張は残る：プリンシパルが真の最大額10万ドルに対して8万ドルの最大価格に署名するのは、交渉者が初回提示を加減するのと同じである。不可能性は交渉段階と同じ力でパラメータ設定段階にも適用される。

プロトコルが達成するのは、交渉過程そのものにおける情報漏洩の低減である。相手方はエージェントがどの程度迅速に譲歩したか、何ラウンドかかったか、どのような中間提示がなされたかを観察できない。経験豊富な交渉者が体系的に搾取するこの中間情報は、封印され破壊される。

1.1 関連研究

ハードウェアエンクレープによる秘匿計算は、Oasis Network や Secret Network など、ブロックチェーン文脈で探索されてきた。これらは非公開スマートコントラクト実行を可能にするが、自律エージェント間の複数ラウンドにわたる相対交渉は対象としていない。

多者間計算（MPC）[2] は私的入力に対する共同計算を入力を開示せずに可能にする。しかし MPC は計算を回路として表現することを要求し、相対取引の中核である自由形式の自然言語交渉には適用できない。

Yao の Garbled Circuits [3] およびプライバシー保護型交渉に関する後続研究 [4] は、私的入力による二者間計算を扱うが、自由形式のエージェント対話ではなく事前定義されたプロトコルに限定される。

完全準同型暗号 [7] は原理的には暗号化された交渉状態上の計算を可能にするが、現行の実装は LLM 推論に対して数桁の性能不足がある。

ダークプール [5][6] は代替可能トークンスワップの情報漏洩を解決する。相対取引は代替不可能な複雑な資産を扱い、単純な価格マッチングではなく多次元交渉を必要とする。

1.2 主張の範囲と限界

プロトコルは情報二重使用問題の第2層（交渉時の漏洩）に対処する。第1層（発見時の漏洩 — 関心表明が需要を暴露）や結果からの推論（決済価格や不成立結果が情報を伝達）は完全には解決しない。これらの残存する漏洩チャンネルは第6節で議論する。

2. 情報の二重使用問題

2.1 定義

相対取引において、私的情報は相反する二つの目的に使用される：

1. **合意の到達**：双方が相互に受容可能な条件を見つけるために選好を伝達しなければならない。
2. **個別余剰の最大化**：各当事者は選好を秘匿し、相手方による価値搾取を防ぎたい。

(1) に必要な情報が (2) で悪用される情報と同一であることが根本的な緊張を生む。我々はこれを**情報の二重使用**と呼ぶ：取引を促進するために一度使用された私的情報が、条件を悪化させるために再度使用される。

2.2 三つの層

問題は取引ライフサイクルの3つの異なる時点で顕在化する：

第1層：発見時の漏洩。資産への関心表明が需要を暴露する。買い手が特許権者に連絡した時点で、その特許が戦略的価値を持つことが暴露される。

第2層：交渉時の搾取。各オファーとカウンターオファーがシグナルとなる。アンカリング効果、応答タイミング、譲歩パターン、さらには交渉を続行する選択自体が私的評価額に関する情報を漏洩させる。

第3層：決済後の残存。取引成立後、仲介者は双方の留保価格と交渉行動の完全な知識を保持する。

3. プロトコル設計

3.1 取引ライフサイクル

取引は6つの状態を遷移する：出品 → マッチ → 交渉中 → 合意 → 決済完了。合意前のいずれの時点でもキャンセル可能。

出品。売り手がハッシュ化した資産記述と最大取引額を公開し、発見ボンドを供託する。

マッチ。買い手が関心を表明し同額のボンドを供託する。

交渉中。 双方がボンドをエスカレートする。各当事者が AI エージェントの許容範囲を定義するパラメータセットに署名する。署名済みパラメータがハードウェア隔離エンクレーブにロードされ、エージェントが構造化メッセージプロトコルで交渉する。いずれのエージェントもエンクレーブ外と通信できない。

合意。 双方が最高段階のボンドにエスカレートする。合意ハッシュとエンクレーブ証明が決済層に記録される。

決済完了。 取引額が買い手から売り手に移転される（手数料差引後）。ボンド返還。

キャンセル。 交渉開始前はペナルティなしでボンド返還。交渉中のキャンセルではキャンセル側のボンドがスラッシュされる：半分が相手方、半分が保険プール。

3.2 ハードウェアエンクレーブによる情報封印

エージェントは Trusted Execution Environment (Intel TDX、AMD SEV-SNP) 内で動作する。エンクレーブはメモリ隔離とリモート証明を提供する。交渉完了時にメモリゼロ化手順を実行する。破壊の標準化された証明は活発な開発領域であり、実装はプラットフォーム固有の証明機構を通じてこの特性を示さなければならない。

3.3 信頼仮定

エンクレーブはハードウェアベンダーへの信頼を要求する。これは数学的困難性仮定とは質的に異なる：ECDSA のセキュリティは数学的予想に基づくが、エンクレーブのセキュリティはハードウェア製造とファームウェアに基づき、サプライチェーンリスクや実装バグの影響を受ける。我々はこのトレードオフを受け入れる。代替案 — 秘匿性保証が全くないこと — は厳密に劣るからである。保険プールが破綻の経済的帰結を制限する。

3.4 なぜ暗号通貨が決済ルールか

エージェント間決済にはプログラム可能で許可不要な決済ルールが必要である。従来の決済手段（銀行振込、クレジットカード）は人間の承認を要し、数時間から数日かかり、カウンターパーティリスクを伴う。L2チェーン上のステーブルコインは秒単位の確定性、完全なプログラム可能性、無視できる取引コストを提供する — 自律エージェント運用と互換性のある唯一の決済ルールである。

スマートコントラクトはアトミック決済（取引額とボンド返還を1トランザクションで）、プログラムのボンドエスカレーション、不変の監査証跡を提供する。

3.5 エージェント設計

各エージェントはエンクレーブ内で動作する言語モデルであり、プリンシパルの署名済みパラメータに撤回不能な委任として束縛される。エージェントは交互ターンで構造化メッセージを交換し、合意に達するか、パラメータ境界に到達するか、ラウンド制限を超過するまで続ける。これはエージェントの行動空間を制約するが、非決定性を排除しない — 交渉の質は基盤モデルの能力に依存する。エージェントランタイムは未実装であり、現在のリリースは決済層のみをカバーする。

4. 経済モデル

4.1 手数料

決済時に0.3%の手数料を徴収。買い手が取引額全額を送金し、売り手は手数料差引後の金額を受領する。手数料はプロトコルの保険プールと運用トレジャリーに送金される。

4.2 ボンド

ボンドはスパム防止と経済的救済を兼ねる。各段階のボンド額は：

$$B(d, \text{stage}) = \text{clamp}(d \cdot r_{\text{stage}}, B_{\min}, B_{\max})$$

段階	料率	最小	最大
発見	1%	\$1	\$1,000
交渉	3%	\$5	\$5,000
実行	10%	\$10	\$50,000

エスカレーションは差分のみ。決済完了でボンド返還。紛争時、違反者のボンドは相手方と保険プールに等分される。

ボンドはロック資本であり消費資本ではない。決済完了した取引の非回収コストは0.3%手数料のみである。

4.3 保険プール

保険プールはプロトコル手数料とスラッシュされたボンドの50%で資金調達される。エンクレーブ違反請求に対する経済的救済を提供する。プール残高と請求履歴はオンチェーンで公開検証可能である。

5. セキュリティ分析

5.1 エンクレーブ違反

プロトコルの秘匿性はハードウェアエンクレーブの完全性に依存する。違反確率は非ゼロである。保険プールが経済的帰結を制限するが、回復を保証しない。TEE の歴史的脆弱性（Foreshadow、ÆPIC Leak、CacheOut）はエンクレーブセキュリティが絶対ではないことを示す。

5.2 経済的攻撃

ボンドグリーフィング。コスト：攻撃者自身のボンド（取引額の3%以上）。利益：相手方の時間浪費。最低ボンドにより非自明なコストが保証される。

シビル取引。プロトコルは自己取引に対する報酬を提供しない。0.3%手数料は相殺的インセンティブのない純粋なコストである。

5.3 決済の完全性

決済層は厳密な状態機械を強制する。各遷移はボンドエスカレーション、暗号署名、エンクレーブ証明を要求する。管理者オーバーライドは存在しない。

6. 制約

ハードウェアベンダー信頼。秘匿性はエンクレーブベンダーの完全性に依存する。数学的困難性仮定とは異なり、サプライチェーンと製造プロセスに関わる。

発見時の漏洩。プロトコルは発見フェーズを封印しない。関心表明とボンド供託は観察可能な行為であり、需要を暴露する。

結果からの漏洩。決済価格は私的評価額を部分的に暴露する。不成立結果は相手方の留保価格の境界を提供する。

ボンドの側チャンネル。ボンド額は取引額に比例し公開観察可能であり、取引規模を第三者に暴露する。

オンチェーン証明。現在の実装は証明ハッシュを保存するが暗号的に検証しない。検証にはプラットフォーム固有の TEE 証明サービスとの統合が必要。

プロトコル非対称性。売り手が最大取引額を設定し、買い手にはオンチェーンの同等物がない。プロトコルは構造的に売り手始動型である。

エージェント非決定性。 言語モデルは確率的である。同一パラメータが異なる交渉結果を生みうる。

法的執行可能性。 プロトコルは暗号的合意ハッシュを生成するが、ほとんどの法域ではオンチェーン状態ではなく法的契約が執行力を持つ手段である。

7. 結論

相対取引の交渉過程における私的情報の漏洩を低減するプロトコルを提示した。エンクレーブの完全性を条件として、交渉動態 — オファー、カウンターオファー、タイミング、譲歩パターン — を取引終了後に両当事者の観察から除去する。

プロトコルは情報二重使用問題を完全には解決しない。発見時の漏洩、結果からの推論、パラメータ設定のインセンティブは残る。封印するのは最も豊かな搾取可能情報の源泉：交渉過程そのものである。

リファレンス実装はオープンソースソフトウェアとして公開されている。

参考文献

- [1] R. Myerson and M. Satterthwaite, "Efficient Mechanisms for Bilateral Trading," *Journal of Economic Theory*, vol. 29, pp. 265-281, 1983.
- [2] O. Goldreich, S. Micali, and A. Wigderson, "How to Play Any Mental Game," *STOC*, 1987.
- [3] A. Yao, "Protocols for Secure Computations," *FOCS*, 1982.
- [4] R. Moraffah and B. Sankar, "Privacy-Preserving Multi-Round Negotiations," *IEEE Transactions on Information Forensics and Security*, 2021.
- [5] Renegade, "On-Chain Dark Pool," 2023.
- [6] Penumbra Labs, "A Private DEX and Shielded Pool," 2023.
- [7] C. Gentry, "Fully Homomorphic Encryption Using Ideal Lattices," *STOC*, 2009.